

Variables Aleatorias Discretas - Distribución Hipergeométrica - Distribución Poisson

Agenda

Repaso

Distribución Hipergeométrica

Distribución Poisson

¿Qué modela la distribución Binomial

Contexto

El número total de éxitos observados entre los n ensayos de un experimento binomial. Un experimento binomial cumple las siguientes condiciones:

- ▶ Consta de n repeticiones idénticas de un ensayo.
- ▶ En cada repetición solo hay dos resultados posibles: **éxito** (E) o **fracaso** (F).
- ▶ Las repeticiones son independientes, lo que significa que el resultado de cualquier repetición particular no influye en el resultado de ninguna otra.
- ▶ La probabilidad de éxito $p = P(E)$ es constante en todas las repeticiones.

Distribución Binomial

Notación

$$X \sim B(n, p).$$

f.d.p, esperanza y varianza

Los valores que puede tomar esta variable son:

$R_X = \{0, 1, 2, \dots, n\}$. La función de frecuencia de X es

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k} \quad \text{para } k = 0, 1, 2, \dots, n$$

$$\mathbb{E}(X) = np$$

$$\text{Var}(X) = np(1 - p)$$

$$\sigma_X = dt(X) = \sqrt{np(1 - p)}$$



¿Qué modela la distribución geométrica?

Contexto

La distribución geométrica modela el número de intentos necesarios hasta obtener el primer éxito en una secuencia de ensayos de Bernoulli independientes.

- ▶ se realizan repeticiones independientes e idénticas de un ensayo **hasta** el primer éxito
- ▶ Probabilidad de éxito es constante igual a p

Variable aleatoria geométrica

Sea X : “Número de repeticiones del ensayo hasta el primer éxito”
 X sigue una distribución geométrica con parámetro p

f.d.p de la distribución Geométrica

Función de probabilidad

$$P(X = k) = (1 - p)^{k-1} \cdot p \quad \text{para } k = 1, 2, 3, \dots$$

Interpretación

- ▶ $(1 - p)^{k-1}$: Probabilidad de $k - 1$ fracasos consecutivos
- ▶ p : Probabilidad de éxito en el k -ésimo intento

Notación

$$X \sim G(p)$$

Fórmula para la Función de distribución acumulada

Fórmula de la Fda para $k = 1, 2, 3 \dots$, esperanza y varianza

$$F(k) = P(X \leq k) = 1 - (1 - p)^k$$

es la probabilidad de tener éxito en los primeros k intentos.

$$\begin{aligned}\mathbb{E}(X) &= \frac{1}{p} \\ \text{Var}(X) &= \frac{1-p}{p^2} \\ \text{dt}(X) &= \frac{\sqrt{1-p}}{p}\end{aligned}$$

¿Qué modela la distribución hipergeométrica?

Contexto

Modela el número de éxitos al extraer una muestra **sin reemplazo** de una población finita que contiene dos tipos de elementos.

Ejemplo típico



De una urna con N bolillas:

- ▶ M bolillas rojas (éxitos)
- ▶ $N - M$ bolillas negras (fracasos)
- ▶ Se extraen n bolillas **sin reemplazo**
- ▶ X : Número de bolillas rojas extraídas

Notación

$$X \sim H(n, M, N)$$




Población: $N = 20$ Éxitos: $M = 5$ Fracasos: $N - M = 15$ Muestra: $n = 3$ Extraemos $n = 3$ bolillas sin reemplazo $X = 1$ éxito en la muestra

- ▶ $N = 20$: Tamaño total de la población
- ▶ $M = 5$: Número de éxitos (bolillas rojas)
- ▶ $n = 3$: Tamaño de la muestra
- ▶ X : Número de éxitos en la muestra

Cálculo de Probabilidad: $P(X = 1)$

Población: 20 bolillas



→ $\binom{5}{1} = 5$: Formas de elegir 1 roja de 5

→ $\binom{15}{2} = 105$: Formas de elegir 2 negras de 15

→ $\binom{20}{3} = 1140$: Formas de elegir 3 bolillas

Cálculo paso a paso

$$P(X = 1) = \frac{\binom{5}{1} \binom{15}{2}}{\binom{20}{3}} = \frac{(5) \cdot (105)}{1140} = \frac{525}{1140} \approx 0.4605$$

Aproximadamente 46 % de probabilidad de obtener exactamente 1 bolilla roja

Función de probabilidad hipergeométrica

Función de probabilidad

Si $X \sim H(n, M, N)$

$$p(k) = P(X = k) = \frac{\binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}}$$

para $\max(0, n - (N - M)) \leq k \leq \min(n, M)$

Las restricciones son consecuencia de:

- ▶ k no puede ser menor que 0 ni mayor que n
- ▶ No se pueden extraer más éxitos de los que hay ($k \leq M$)
- ▶ No se pueden extraer más fracasos de los que hay ($n - k \leq N - M$)

Ejemplo: Control de calidad

Escenario

Un repositorio tiene 50 microservicios. Se identificó que 8 de ellos contienen código vulnerable. Un equipo de auditoría selecciona 5 microservicios al azar para revisar **sin reemplazo**. Calcular la probabilidad de que la auditoría no encuentre vulnerabilidades y la de que encuentre al menos una.

Parámetros

$N = 50$ (total de servicios)

$M = 8$ (servicios vulnerables)

$n = 5$ (muestra inspeccionada)

X = número de microservicios vulnerables seleccionados

$X \sim H(5, 8, 50)$

Función de probabilidad

$$p(0) = P(X = 0) = \frac{\binom{8}{0} \binom{42}{5}}{\binom{50}{5}} \approx 0.4015$$

$$p(1) = P(X = 1) = \frac{\binom{8}{1} \binom{42}{5}}{\binom{50}{5}} \approx 0.4226$$


$$p(2) = P(X = 2) = \frac{\binom{8}{2} \binom{42}{4}}{\binom{50}{5}} \approx 0.1517$$

$$p(3) = P(X = 3) = \frac{\binom{8}{3} \binom{42}{3}}{\binom{50}{5}} \approx 0.0228$$

$$p(4) = P(X = 4) = \frac{\binom{8}{4} \binom{42}{2}}{\binom{50}{5}} \approx 0.0014$$

$$p(5) = P(X = 5) = 1 - \sum_{k=0}^4 p(k) \approx 0$$

Gráfica de la distribución hipergeométrica



Distribución Hipergeométrica: $N = 50$, $M = 8$, $n = 5$

Interpretación para el Equipo de Seguridad

$$P(X = 0) = p(0) = \frac{\binom{8}{0}\binom{42}{5}}{\binom{50}{5}} \approx 0.4015$$

Respuesta en % de Probabilidad

- ▶ **Pasar la auditoría:** 40.15 % de que no se encuentren vulnerabilidades

$$P(X \geq 1) = 1 - P(X = 0) = 0.5985$$

Respuesta en % de Probabilidad

- ▶ **Detectabilidad:** 59.85 % de que se encuentre al menos 1 vulnerabilidad

Esperanza y varianza

Fórmulas

Si $X \sim H(n, M, N)$, entonces:

$$\mathbb{E}(X) = n \cdot \frac{M}{N}$$

$$\text{Var}(X) = n \cdot \frac{M}{N} \cdot \frac{N - M}{N} \cdot \frac{N - n}{N - 1}$$

Aplicación al ejemplo

$$\mathbb{E}(X) = 5 \cdot \frac{8}{50} = 0.8 \text{ vulnerabilidades}$$

$$\text{Var}(X) = 5 \cdot \frac{8}{50} \cdot \frac{42}{50} \cdot \frac{44}{49} \approx 0.617$$

$$dt(X) \approx \sqrt{0.617} \approx 0.785$$

Aplicación: Muestreo de aceptación

Decisión de calidad

Un lote de 100 productos se acepta si no más de 2 de 10 muestreados son defectuosos. Si hay 10 defectuosos en el lote:

Cálculo de probabilidad de aceptación

X = cantidad de defectuosos muestreados $X \sim H(10, 10, 100)$

$$P(\text{aceptar}) = P(X \leq 2) = P(X = 0) + P(X = 1) + P(X = 2)$$

$$P(X = 0) = \frac{\binom{10}{0} \binom{90}{10}}{\binom{100}{10}} \approx 0.3305$$

$$P(X = 2) = \frac{\binom{10}{2} \binom{90}{8}}{\binom{100}{10}} \approx 0.2015$$

$$P(X = 1) = \frac{\binom{10}{1} \binom{90}{9}}{\binom{100}{10}} \approx 0.4080$$

$$P(X \leq 2) \approx 0.9400$$

94 % de probabilidad de aceptar un lote con 10 % defectuoso

Comparación con la distribución binomial

De una urna con N bolillas:

- ▶ M bolillas rojas (éxitos)
- ▶ $N - M$ bolillas negras (fracasos)

Hipergeométrica

- ▶ Se extraen n bolillas **sin reemplazo**
- ▶ los resultados de las extracciones **no son independientes**

Binomial

- ▶ Se extraen n bolillas **con reemplazo**
- ▶ Probabilidad de éxito:
$$p = \frac{M}{N}.$$
- ▶ el resultado de una extracción particular no influye en el resultado las otras (**independientes**).

En ambos casos: $X =$ Número de bolillas rojas extraídas

Comparativa

Diferencias con Binomial

	Binomial	Hipergeométrica
Reemplazo	Sí	No
Independencia	Sí	No

Recordemos...

En general, al extraer una muestra **sin reemplazo** de una población finita, si la población es grande y la muestra extraída no supera el 5 % del tamaño de la población, cada extracción puede considerarse “prácticamente” independiente de las anteriores y es posible analizar el experimento como binomial.

Aproximación a la distribución binomial

Condición de aproximación

Cuando N es grande y n es pequeño relativo a N (al menos $n/N \leq 0.05$), la hipergeométrica se aproxima a una binomial:

$$H(n, M, N) \approx B(n, p = \frac{M}{N})$$

Ejemplo de aproximación

Para $N = 1000$, $M = 100$, $n = 10$:

$$P_{\text{hip}}(X = 2) = \frac{\binom{100}{2} \binom{900}{8}}{\binom{1000}{10}} \approx 0.1937$$

$$P_{\text{bin}}(X = 2) = \binom{10}{2} (0.1)^2 (0.9)^8 \approx 0.1937$$

¿Qué modela la distribución Poisson?

Contexto

La distribución de Poisson sirve para modelizar el número de eventos que ocurren aleatoriamente en el tiempo o en una región.

Ejemplos

- ▶ Número de requests por segundo a un servidor web
- ▶ Número de bacterias por volumen de fluido
- ▶ Cantidad de logins por minuto a una aplicación
- ▶ Número de plantas de determinada especie distribuidos aleatoriamente en un área.

Función de probabilidad Poisson

Definición formal

Una v.a. X con rango $R_X = \{0, 1, 2, \dots\}$ tiene distribución de Poisson con parámetro λ , $\lambda > 0$, si su f.d.p es

$$p(k) = P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!} \quad \text{para } k = 0, 1, 2, \dots$$

Notación

$$X \sim P(\lambda)$$

Ejemplo: Requests a un servidor web

Escenario

Consideremos un servidor web tal que el número de requests que recibe por segundo es una v.a. Poisson con parámetro $\lambda = 3$. ¿Cuál es la probabilidad de recibir exactamente 5 requests en un segundo?

Definición de la variable, distribución, parámetro


X = número de requests que se reciben en un segundo, $X \sim P(3)$

Cálculo

$$P(X = 5) = \frac{e^{-\lambda} \lambda^k}{k!} = \frac{e^{-3} \cdot 3^5}{5!} \approx \frac{0.0498 \cdot 243}{120} \approx 0.1008$$


Hay una probabilidad de 0.1008 de recibir exactamente 5 requests en un segundo.

Gráfica: Distribución Poisson ($\lambda = 3$)




- ▶ Máxima probabilidad en $k = 2$ y $k = 3$ (moda)
- ▶ Probabilidades decrecientes para $k > 3$
- ▶ Cola larga hacia la derecha (Distribución asimétrica positiva)


Distribución de Poisson $P(\lambda)$ para diferentes λ




Distribución de Poisson $P(\lambda)$ para diferentes λ




Distribución de Poisson $P(\lambda)$ para diferentes λ




Distribución de Poisson $P(\lambda)$ para diferentes λ



Distribución de Poisson $P(\lambda)$ para diferentes λ



Distribución de Poisson $P(\lambda)$ para diferentes λ



Análisis de la f.d.p. de una v.a. con distribución de Poisson

Para diferentes valores de λ

- ▶ λ pequeño: Distribución muy asimétrica a la derecha
- ▶ λ moderado: Distribución ligeramente asimétrica a la derecha
- ▶ λ grande: Distribución aproximadamente simétrica
- ▶ A medida que λ aumenta, la distribución se desplaza hacia la derecha y se “aplata”.

Esperanza y varianza

Propiedades

Si $X \sim P(\lambda)$, entonces

- ▶ $E[X] = \lambda$
- ▶ $\text{Var}(X) = \lambda$
- ▶ $\text{dt}(X) = \sqrt{\lambda}$

Volviendo al ejemplo de Requests a un servidor web

$X \sim P(3)$ entonces $\lambda = 3$.

- ▶ $E[X] = 3$
- ▶ $\text{Var}(X) = 3$ y $\text{dt}(X) = \sqrt{3}$

El número medio de requests que el servidor recibe por seg. es 3.

Proceso Temporal de Poisson

Definición y Características

Un proceso se denomina **proceso temporal de Poisson** cuando cumple con las siguientes características:

- ▶ **Invariancia:**

Las condiciones no cambian con el tiempo.

- ▶ **Falta de memoria:**

Lo que ocurre en un intervalo $[0, t)$ no influye en lo que sucede en $[s, r)$ para $r > s > t$.

- ▶ **Sucesos aislados:**

La probabilidad de que ocurra más de un evento en un intervalo muy corto es despreciable comparada con la probabilidad de que ocurra uno o ninguno.

Modelamiento del Proceso

Distribución de Poisson

Si X_t es la variable aleatoria que cuenta el número de eventos que ocurren en un proceso de Poisson en un intervalo de longitud t , entonces:

$$p(x) = P(X = x) = e^{-c \cdot t} \frac{(c \cdot t)^x}{x!} \quad \text{para } x = 0, 1, 2, \dots$$

Esto significa que X_t sigue una distribución de Poisson con parámetro:

$$\lambda_t = c \cdot t$$

Donde c es la **tasa de ocurrencia**, es decir, el número promedio de eventos por unidad de tiempo.

Aplicación: Planificación de capacidad

Problema

Un API gateway procesa requests de manera aleatoria según un proceso de Poisson y maneja en promedio 10 requests por segundo. Se quiere calcular la probabilidad de que se procesen más de 15 solicitudes en un segundo.

X = número de requests en un segundo, $X \sim P(\lambda)$

Cálculo de λ : $c = 10$ y $t = 1$ seg, entonces $\lambda = c \cdot t = 10$

$$P(X \leq 15) = \sum_{k=0}^{15} \frac{e^{-10} \cdot 10^k}{k!} = \frac{e^{-10} \cdot 10^0}{0!} + \dots + \frac{e^{-10} \cdot 10^{15}}{15!} \approx 0.9513$$

$$P(X > 15) = 1 - 0.9513 = 0.0487$$

La probabilidad de que se procesen más de 15 requests en un segundo es de 0.048

Tablas de Distribución Poisson Acumulativa

- ▶ Las tablas proporcionan los valores de la función de distribución acumulada (fda) para $X \sim P(\lambda)$.
- ▶ Se tabulan $F(k) = P(X \leq k) = \sum_{i=0}^k P(X = i)$ para diferentes λ .

Valores disponibles

- ▶ λ : 0.1, ..., 0.9, 1, ..., 10, 12, 15, 17, 20 y 25.
- ▶ k : 0, 1, 2, ...

Estructura de la tabla

- ▶ **Primera columna:** Valores de k
- ▶ **Primera fila:** Valores de λ
- ▶ **Intersección:** $F(k) = P(X \leq k)$ para $X \sim P(\lambda)$

Poisson													
k	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	1	2	3	4
0	0.9048	0.8187	0.7408	0.6703	0.6065	0.5488	0.4966	0.4493	0.4066	0.3679	0.1353	0.0498	0.0183
1	0.9953	0.9825	0.9631	0.9384	0.9098	0.8781	0.8442	0.8088	0.7725	0.7358	0.4060	0.1991	0.0916
2	0.9998	0.9989	0.9964	0.9921	0.9856	0.9769	0.9659	0.9526	0.9371	0.9197	0.6767	0.4232	0.2381
3	1.0000	0.9999	0.9997	0.9992	0.9982	0.9966	0.9942	0.9909	0.9865	0.9810	0.8571	0.6472	0.4335
4		1.0000	1.0000	0.9999	0.9998	0.9996	0.9992	0.9986	0.9977	0.9963	0.9473	0.8153	0.6288
5				1.0000	1.0000	1.0000	0.9999	0.9998	0.9997	0.9994	0.9834	0.9161	0.7851
6							1.0000	1.0000	1.0000	0.9999	0.9955	0.9665	0.8893

Ejemplo: $X \sim P(0.9)$

- ▶ $F(5) = P(X \leq 5) = 0.9997$
- ▶ $p(5) = P(X = 5) = F(5) - F(4) = 0.9997 - 0.9977 = 0.002$

Aplicación: Planificación de capacidad (continuación)

Problema

Para la misma API gateway se quiere calcular la probabilidad de que se procesen más de 30 solicitudes en 2 segundos.

X_2 = número de requests en 2 segundos, $X \sim P(\lambda)$

Cálculo de λ : $c = 10$ y $t = 2$ seg, entonces $\lambda = c \cdot t = 20$

$$P(X_2 \leq 30) = \sum_{k=0}^{30} \frac{e^{-20} \cdot 20^k}{k!} \approx 0.9865 \text{ (por tabla)}$$

$$P(X_2 > 30) = 1 - 0.9865 = 0.0135$$

La probabilidad de que se procesen más de 30 requests en dos segundos es de 0.0135.

Proceso Espacial de Poisson

Definición

Se denomina **proceso espacial de Poisson** cuando cumple con las siguientes características:

- ▶ **Homogeneidad espacial:**

La probabilidad de que un punto esté en una región dada sólo depende del tamaño de esa región (área o volumen) y no de su forma o posición.

Proceso Espacial de Poisson

Definición

Se denomina **proceso espacial de Poisson** cuando cumple con las siguientes características:


- ▶ **Homogeneidad espacial:**

La probabilidad de que un punto esté en una región dada sólo depende del tamaño de esa región (área o volumen) y no de su forma o posición.

- ▶ **No interacción:**

Lo que ocurre en una región es independiente de lo que ocurre en otra, si no se superponen.

Ejemplo Visual de Proceso Espacial de Poisson



Densidad constante: $c = 0.6$ puntos/unidad²

Número esperado en región de área a : $\lambda = c \times a$

Modelamiento Matemático

La variable aleatoria X_a que mide el número de “puntos” en una región de área o volumen a , tiene distribución de Poisson con parámetro:

$$\lambda_a = c \cdot a$$

donde:

- ▶ c : tasa de ocurrencia del proceso (puntos por unidad de área/volumen)
- ▶ a : tamaño de la región (área o volumen)
- ▶ $X_a \sim P(c \cdot a)$

$$P(X_a = k) = e^{-c \cdot a} \frac{(c \cdot a)^k}{k!} \quad \text{para } k = 0, 1, 2, \dots$$

Distribución de estrellas en el espacio

Problema:

En una región del espacio, las estrellas se distribuyen según un proceso espacial de Poisson con densidad $c = 0.1$ estrellas por año-luz cúbico.

¿Cuál es la probabilidad de encontrar exactamente 3 estrellas en un volumen de 10 años-luz cúbicos?

Solución: $\lambda = c \cdot a = 0.1 \cdot 10 = 1$

X_{10} = cantidad de estrellas en 10 años-luz cúbicos $X_{10} \sim P(10)$

$$P(X_{10} = 3) = e^{-1} \frac{1^3}{3!} = \frac{e^{-1}}{6} \approx 0.0613$$

Respuesta: La probabilidad de encontrar exactamente 3 estrellas en un volumen de 10 años-luz cúbicos es aproximadamente 0.0613.

Relación con la distribución binomial

Aproximación Poisson-Binomial

Si $X \sim B(n, p)$ se puede demostrar que cuando n es grande y p pequeño, vale la siguiente aproximación: $np = \lambda$ constante:

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k} \approx \frac{e^{-np} (np)^k}{k!} \quad \text{para } k \in R_x$$

Es decir, $X \approx P(np)$. Aquí $\approx$ significa que tiene aproximadamente esa distribución.

Ventajas de la aproximación

- ▶ Evita números combinatorios grandes
- ▶ Buena aproximación cuando $n \geq 20$ y $p \leq 0.05$ y muy buena si $n \geq 100$, $p \leq 0.01$ y $np \leq 20$.

Errores en transmisión

Problema:

De 1000 paquetes, cada uno tiene 0.3 % de probabilidad de error.
Calcular la probabilidad de que al menos 3 paquetes tengan error.

X = cantidad de paquetes con error entre 1000

$X \sim B(1000, 0.003)$

$$\begin{aligned} P(X = k) &= \binom{1000}{k} (0.003)^k (0.997)^{1000-k} \\ &\approx \frac{e^{-3} \cdot 3^k}{k!} \quad (\lambda = 1000 \cdot 0.003 = 3) \end{aligned}$$

$$\begin{aligned} P(X \geq 3) &= 1 - P(X < 3) = 1 - P(X \leq 2) \\ &= 1 - [P(X = 0) + P(X = 1) + P(X = 2)] = 1 - F(2) \\ &\approx 1 - 0.4232 = 0.5768 \text{ por tabla de la dist. Poisson} \end{aligned}$$