

Suma de Variables Aleatorias y Teorema Central de Límite

Agenda

Repaso

Distribución de la Suma de v. a. independientes

Suma de v. a. normales independientes

TCL

Función de n Variables Aleatorias

Definición General

Dada una función $H : \mathbb{R}^n \rightarrow \mathbb{R}$, definimos:

$$Z = H(X_1, X_2, \dots, X_n)$$

Ejemplos Comunes

- ▶ **Suma:** $Z = X_1 + X_2 + \dots + X_n$
- ▶ **Promedio:** $Z = \frac{X_1 + X_2 + \dots + X_n}{n}$

Combinación Lineal de n Variables

Definición

Una **combinación lineal** de n variables aleatorias es:

$$Z = a_1X_1 + a_2X_2 + \cdots + a_nX_n = \sum_{i=1}^n a_iX_i$$

donde $a_1, a_2, \dots, a_n$ son constantes reales.

Esperanza de una Combinación Lineal

$$E[Z] = E \left[\sum_{i=1}^n a_iX_i \right] = \sum_{i=1}^n a_iE[X_i]$$

Independencia y esperanza

Intuitivamente decimos que las variables $X_1, X_2, \dots, X_n$ son **independientes** si el valor que toma una de ellas (cualquiera) no influye de ninguna manera sobre el valor que toman las restantes.

Teorema General

Sean $X_1, X_2, \dots, X_n$ variables aleatorias **independientes**. Entonces:

$$E[X_1 X_2 \cdots X_n] = E[X_1] E[X_2] \cdots E[X_n]$$

Covarianza

Definición:

$$\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y]$$

Por tanto, del teorema anterior:

Corolario

Si X e Y son independientes:

$$\text{Cov}(X, Y) = 0.$$

Varianza de la Suma

Varianza de la Suma

Para cualquier par de variables:

$$V[X + Y] = V[X] + V[Y] + 2\text{Cov}(X, Y)$$

Varianza de la Suma

Si X e Y son independientes ($\text{Cov}(X, Y) = 0$):

$$V[X + Y] = V[X] + V[Y]$$

Generalización para n Variables Independientes

Si $X_1, \dots, X_n$ son independientes:

$$V\left[\sum_{i=1}^n X_i\right] = \sum_{i=1}^n V[X_i]$$

Ejemplo: Binomial como Suma de Bernoulli

Recordemos...

El número X total de éxitos observados entre las n repeticiones independientes de un ensayo en un experimento binomial es una v. a. $X \sim B(n, p)$.

En cada repetición observamos una variable aleatoria X_i que toma sólo dos valores: 0 y 1, con probabilidades p y $1 - p$ respectivamente.

$$X_i = \begin{cases} 1 & \text{si en la repetición ocurre éxito} \\ 0 & \text{caso contrario (fracaso)} \end{cases}$$

Cada X_i tiene **distribución de Bernoulli** con parámetro p y son independientes ya que las repeticiones son independientes.

Ejemplo: Binomial como Suma de Bernoulli

Representación de la Binomial

Sea $X \sim B(n, p)$. Podemos escribir:

$$X = X_1 + X_2 + \cdots + X_n$$

donde cada $X_i \sim \text{Bernoulli}(p)$ y son independientes.

Suma de Variables Binomiales Independientes

Teorema

Sean $X \sim B(n_1, p)$ e $Y \sim B(n_2, p)$ variables aleatorias **independientes**. Entonces:

$$X + Y \sim B(n_1 + n_2, p)$$

Demostración:

Usaremos la representación de las binomiales como suma de variables de Bernoulli.

- ▶ Como $X \sim B(n_1, p)$, podemos escribir:

$$X = X_1 + X_2 + \cdots + X_{n_1}$$

donde cada $X_i \sim \text{Bernoulli}(p)$ e independientes.

- ▶ Como $Y \sim B(n_2, p)$, podemos escribir:

$$Y = Y_1 + Y_2 + \cdots + Y_{n_2}$$

donde cada $Y_j \sim \text{Bernoulli}(p)$ e independientes.

- ▶ Por la independencia entre X e Y , todas las X_i e Y_j son independientes.

Demostración:(continuación)

- Consideremos la suma:

$$X + Y = (X_1 + \cdots + X_{n_1}) + (Y_1 + \cdots + Y_{n_2})$$

- Esto es equivalente a:

$$X + Y = Z_1 + Z_2 + \cdots + Z_{n_1+n_2}$$

donde $Z_1, Z_2, \dots, Z_{n_1+n_2}$ son variables Bernoulli(p) independientes.

- Por definición, esta suma de $n_1 + n_2$ variables Bernoulli independientes con parámetro p tiene distribución:

$$X + Y \sim B(n_1 + n_2, p)$$

Suma de Variables Poisson Independientes

Teorema

Sean $X \sim P(\lambda_1)$ e $Y \sim P(\lambda_2)$ variables aleatorias **independientes**. Entonces:

$$X + Y \sim P(\lambda_1 + \lambda_2)$$

Ejemplo: Aplicación de Suma de Poisson

Problema

En un centro de llamadas, el número de llamadas que llegan a la línea A sigue una distribución Poisson con promedio de 10 llamadas por hora, y a la línea B con promedio de 15 llamadas por hora. Si las llegadas son independientes, ¿cuál es la probabilidad de que en total lleguen más de 30 llamadas en una hora?

- ▶ X : llamadas a la línea A en una hora $\sim P(10)$
- ▶ Y : llamadas a la línea B en una hora $\sim P(15)$
- ▶ X e Y son independientes entonces $X + Y \sim P(25)$

Probabilidad pedida: $P(X + Y > 30) = 1 - P(X + Y \leq 30)$

Por tabla $P(X + Y \leq 30) = 0.8633$ entonces

$$P(X + Y > 30) = 1 - 0.8633 = 0.1367.$$

Generalización para n Variables Aleatorias

Suma de n Variables Independientes

- ▶ Si $X_1, X_2, \dots, X_n$ son variables aleatorias independientes donde $X_i \sim B(n_i, p)$ para todo $i = 1, 2, \dots, n$, entonces:

$$\sum_{i=1}^n X_i \sim B\left(\sum_{i=1}^n n_i, p\right)$$

- ▶ Si $X_1, X_2, \dots, X_n$ son variables aleatorias independientes donde $X_i \sim P(\lambda_i)$ para todo $i = 1, 2, \dots, n$, entonces:

$$\sum_{i=1}^n X_i \sim P\left(\sum_{i=1}^n \lambda_i\right)$$

Estas dos distribuciones comparten la propiedad de que la suma de variables independientes de la misma familia pertenece a la misma familia.

Suma de Variables Normales Independientes

Teorema

Sean $X \sim N(\mu_1, \sigma_1^2)$ e $Y \sim N(\mu_2, \sigma_2^2)$ variables aleatorias **independientes**. Entonces:

$$X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$$

Interpretación

La suma de dos variables normales independientes es también normal, con:

- ▶ Media: suma de las medias individuales
- ▶ Varianza: suma de las varianzas individuales

La independencia es crucial. Si X e Y no son independientes

$$V(X + Y) = \sigma_1^2 + \sigma_2^2 + 2\text{Cov}(X, Y)$$

Generalización: Suma de n Normales Independientes

Teorema

Si $X_1, X_2, \dots, X_n$ son variables aleatorias independientes donde $X_i \sim N(\mu_i, \sigma_i^2)$ para todo $i = 1, 2, \dots, n$, entonces:

$$\sum_{i=1}^n X_i \sim N\left(\sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2\right)$$

Combinación Lineal de Normales Independientes

Teorema (Caso general)

Si $X_1, X_2, \dots, X_n$ son variables aleatorias independientes donde $X_i \sim N(\mu_i, \sigma_i^2)$ para todo $i = 1, 2, \dots, n$, y $a_1, a_2, \dots, a_n$ son constantes reales, entonces:

$$\sum_{i=1}^n a_i X_i \sim N \left(\sum_{i=1}^n a_i \mu_i, \sum_{i=1}^n a_i^2 \sigma_i^2 \right)$$

Casos particulares

- ▶ **Suma:** $a_i = 1$ para todo i
- ▶ **Diferencia:** $X - Y$ con $a_1 = 1, a_2 = -1$
- ▶ **Promedio:** $a_i = \frac{1}{n}$ para todo i

Caso Especial: Promedio de Normales

Teorema (Promedio muestral)

Si $X_1, X_2, \dots, X_n$ son variables aleatorias independientes e idénticamente distribuidas (i.i.d.) con $X_i \sim N(\mu, \sigma^2)$ para todo i , entonces:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

Demostración

Aplicando el teorema de combinación lineal con $a_i = \frac{1}{n}$:

- ▶ Media: $\sum_{i=1}^n \frac{1}{n} \mu = \mu$
- ▶ Varianza: $\sum_{i=1}^n \left(\frac{1}{n}\right)^2 \sigma^2 = \frac{\sigma^2}{n}$

Ejemplo: Aplicación Práctica

Problema

El peso de paquetes sigue $N(500, 20^2)$ gramos. Se toman 4 paquetes al azar de forma independiente.

1. ¿Cuál es la probabilidad de que el peso total de los 4 paquetes sea mayor a 1950 gs?
2. ¿Cuál es la probabilidad de que el promedio esté entre 490 y 510 gramos?

Datos proporcionados

- ▶ $\mu = 500$ gramos (media poblacional)
- ▶ $\sigma = 20$ gramos (desviación estándar poblacional)
- ▶ $n = 4$ selecciones **independientes**

Paso 1: Definición de Variables Aleatorias

Variables individuales

Definimos para cada paquete:

- ▶ X_1 : peso del paquete 1 en gramos
- ▶ X_2 : peso del paquete 2 en gramos
- ▶ X_3 : peso del paquete 3 en gramos
- ▶ X_4 : peso del paquete 4 en gramos

Las variables X_1, X_2, X_3, X_4 son **independientes** entre sí.

Distribución de cada variable

Por el enunciado, cada X_i ($i = 1, 2, 3, 4$) tiene distribución:

$$X_i \sim N(\mu = 500, \sigma^2 = 20^2) = N(500, 400)$$

Paso 2: Distribución del Peso Total

Variable de interés

Definimos la variable T como el peso total de los 4 paquetes:
$$T = X_1 + X_2 + X_3 + X_4$$

Aplicando el teorema de suma de normales

Por el teorema: Si $X_i \sim N(\mu_i, \sigma_i^2)$ independientes, entonces:

$$T = \sum_{i=1}^n X_i \sim N\left(\sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2\right)$$

Cálculo de parámetros

- ▶ Media: $\sum_{i=1}^4 \mu_i = 500 + 500 + 500 + 500 = 4 \times 500 = 2000$
- ▶ Varianza: $\sum_{i=1}^4 \sigma_i^2 = 400 + 400 + 400 + 400 = 4 \times 400 = 1600$
- ▶ Desviación estándar: $\sqrt{1600} = 40$

Paso 3: Resultado Peso Total

Distribución del peso total:

$$T = X_1 + X_2 + X_3 + X_4 \sim N(2000, 1600)$$

Probabilidad solicitada

Queremos calcular:

$$P(T > 1950) = 1 - P(T \leq 1950)$$

Estandarización

Para calcular probabilidades con distribución normal, estandarizamos:

$$Z = \frac{T - \mu_T}{\sigma_T} = \frac{T - 2000}{40} \sim N(0, 1)$$

$$P(T \leq 1950) = P\left(\frac{T - 2000}{40} \leq \frac{1950 - 2000}{40}\right) = P(Z \leq -5/4)$$

Paso 4: Resultado Final

Usando la distribución acumulada

$$P(T > 1950) = 1 - P(T \leq 1950) = 1 - P(Z \leq -5/4) = 1 - \Phi(-1.25)$$

Valor de la tabla normal

► $\Phi(-1.25) = 0.1056$

Respuesta final

$$P(T > 1950) = 1 - 0.1056 = 0.8944$$

Hay un 89.44 % de probabilidad de que el peso total de los 4 paquetes sea mayor a 1950 gramos

Parte 2 - Paso 1: Distribución del Peso Promedio

Variable de interés

Definimos la variable $\bar{X}$ como el peso promedio de los 4 paquetes:

$$\bar{X} = \frac{X_1 + X_2 + X_3 + X_4}{4} = \frac{T}{4}$$

Aplicando el teorema del promedio de normales

Por el teorema: Si $X_i \sim N(\mu, \sigma^2)$ i.i.d., entonces:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

Cálculo de parámetros

- ▶ Media: $\mu = 500$
- ▶ Varianza: $\frac{\sigma^2}{n} = \frac{400}{4} = 100$ Desviación estándar: $\sqrt{100} = 10$

Parte 2 - Paso 2: Resultado Peso Promedio

Distribución del peso promedio

$$\bar{X} \sim N(500, 100)$$

Probabilidad solicitada

Queremos calcular:

$$P(490 \leq \bar{X} \leq 510)$$

donde $\bar{X} \sim N(500, 100)$

Estandarización

Para calcular probabilidades con distribución normal, estandarizamos:

$$Z = \frac{\bar{X} - \mu}{\sigma_{\bar{X}}} = \frac{\bar{X} - 500}{10} \sim N(0, 1)$$

Parte 2 - Paso 3: Cálculo de Probabilidad - Desarrollo

Probabilidad estandarizada

$$\begin{aligned}P(490 \leq \bar{X} \leq 510) &= P\left(\frac{490 - 500}{10} \leq \frac{\bar{X} - 500}{10} \leq \frac{510 - 500}{10}\right) \\&= P(-1 \leq Z \leq 1) = \Phi(1) - \Phi(-1)\end{aligned}$$

Valores de la tabla normal

- ▶ $\Phi(1) = 0.8413$
- ▶ $\Phi(-1) = 1 - \Phi(1) = 1 - 0.8413 = 0.1587$
- ▶ $\Phi(1) - \Phi(-1) = 0.8413 - 0.1587 = 0.6826$

Paso 4: Resultado Final y Verificación

Respuesta final

$$P(490 \leq \bar{X} \leq 510) = 0.6826$$

Interpretación

- Hay un 68.26 % de probabilidad de que el peso promedio de 4 paquetes esté entre 490 y 510 gramos

Teorema Central del Límite (TCL)

Enunciado del Teorema

Sean $X_1, X_2, \dots, X_n$ variables aleatorias **independientes e idénticamente distribuidas** (i.i.d.) con $E(X_i) = \mu$ y $V(X_i) = \sigma^2$. Para n grande, la distribución de $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ es **aproximadamente normal** con media μ y varianza σ^2/n . Formalmente, cuando n es grande:

$$P(\bar{X} \leq a) = P\left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq \frac{a - \mu}{\sigma/\sqrt{n}}\right) \approx \Phi\left(\frac{a - \mu}{\sigma/\sqrt{n}}\right)$$

$\bar{X}$ es llamado **promedio muestral** o **media muestral**.

Formas Equivalentes del TCL

En la práctica

Si $X_1, X_2, \dots, X_n$ son i.i.d., para n suficientemente grande:

$$\bar{X} \approx N\left(\mu, \frac{\sigma^2}{n}\right)$$

$$\sum_{i=1}^n X_i \approx N(n\mu, n\sigma^2)$$

Condiciones y Aplicación Práctica

¿Qué tan grande debe ser n ?

- ▶ **Distribución simétrica:** $n \geq 15$ suele ser suficiente
- ▶ **Distribución moderadamente sesgada:** $n \geq 30$
- ▶ **Distribución muy sesgada:** $n \geq 50$ o más
- ▶ **Regla práctica común:** $n \geq 30$

Tiempos de Ejecución

Problema práctico

Un equipo de desarrollo está optimizando un algoritmo de ordenamiento. Al medir los tiempos de ejecución para ordenar arreglos de tamaño fijo, observan que la distribución de tiempos no es conocida pero tiene media poblacional: $\mu = 160$ ms y desviación estándar: $\sigma = 40$ ms.

Pregunta: ¿Cuál es la probabilidad de que el tiempo promedio de ejecución en 40 pruebas sea menor a 150 ms?

Datos del problema

- ▶ Media poblacional: $\mu = 160$ ms
- ▶ Desviación estándar: $\sigma = 40$ ms
- ▶ Tamaño de muestra: $n = 40$ pruebas independientes



Aplicación del TCL

Condiciones verificadas

- ▶ **Tamaño suficiente:** $n = 40 \geq 30$
- ▶ Las variables $X_i =$ “tiempo de la prueba i ” con $i = 1, \dots, 40$ son i.i.d.

Distribución aproximada del promedio por TCL

$$\bar{X} \approx N\left(\mu, \frac{\sigma^2}{n}\right) = N\left(160, \frac{1600}{40}\right) = N(160, 40)$$

Probabilidad solicitada

Queremos calcular $P(\bar{X} < 150)$

Cálculo de la Probabilidad

Estandarización

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} = \frac{\bar{X} - 160}{6.3246}$$

$$P(\bar{X} < 150) = P\left(\frac{\bar{X} - 160}{6.3246} < \frac{150 - 160}{6.3246}\right) = P(Z < -1.5811)$$

Usando TCL y la tabla normal

$$P(Z < -1.5811) \approx \Phi(-1.5811) = 0.05705$$

$$P(\bar{X} < 150) \approx 0.0571 \quad (5.71\%)$$

Aproximación Normal a la Distribución Binomial

Teorema

Si $X \sim B(n, p)$ y n es grande, entonces:

$$X \approx N(np, np(1 - p))$$

o equivalentemente:

$$Z = \frac{X - np}{\sqrt{np(1 - p)}} \approx N(0, 1)$$

Fundamentación

Recordemos que $X = \sum_{i=1}^n X_i$ donde $X_i \sim \text{Bernoulli}(p)$ i.i.d.

Por TCL: $\frac{X - np}{\sqrt{np(1 - p)}} \approx N(0, 1)$ cuando n es grande.

Condiciones para la Aproximación Binomial

Criterios comunes

La aproximación es buena si:

- ▶ $np \geq 5$ y $n(1 - p) \geq 5$ (criterio conservador)
- ▶ $np \geq 10$ y $n(1 - p) \geq 10$ (criterio más estricto)

Corrección por continuidad

Como la binomial es discreta y la normal es continua, usamos:

$$P(X = k) \approx P(k - 0.5 \leq Y \leq k + 0.5)$$

donde $Y \sim N(np, np(1 - p))$

Corrección por Continuidad - Ejemplos

Reglas de corrección

- ▶ $P(X = k) \approx P(k - 0.5 \leq Y \leq k + 0.5)$
- ▶ $P(X \leq k) \approx P(Y \leq k + 0.5)$
- ▶ $P(X < k) \approx P(Y \leq k - 0.5)$
- ▶ $P(X \geq k) \approx P(Y \geq k - 0.5)$
- ▶ $P(X > k) \approx P(Y \geq k + 0.5)$

Ejemplo: $X \sim B(100, 0.3)$ y $Y \sim N(30, 21)$

- ▶ $P(X = 25) \approx P(24.5 \leq Y \leq 25.5)$
- ▶ $P(X \leq 30) \approx P(Y \leq 30.5)$
- ▶ $P(X > 35) \approx P(Y \geq 35.5)$

Ejemplo: Aproximación Binomial a Normal

Problema

En una fábrica, el 20 % de los artículos son defectuosos. Se toma una muestra de 100 artículos. ¿Cuál es la probabilidad de encontrar entre 15 y 25 defectuosos?

- ▶ X = cantidad de artículos muestreados. $X \sim B(100, 0.2)$
- ▶ Verificación: $np = 20 \geq 5$, $n(1 - p) = 80 \geq 5$
- ▶ Aproximación por TCL: $X \approx N(20, 16)$
- ▶ Sea $Y \sim N(20, 16)$, por corrección por continuidad:

$$\begin{aligned} P(15 \leq X \leq 25) &\approx P(14.5 \leq Y \leq 25.5) \\ &= P\left(\frac{14.5 - 20}{4} \leq Z \leq \frac{25.5 - 20}{4}\right) \\ &= P(-1.375 \leq Z \leq 1.375) = \Phi(1.375) - \Phi(-1.375) \\ &\approx 0.831 \end{aligned}$$

Aproximación Normal a la Distribución Poisson

Teorema

Si $X \sim P(\lambda)$ y λ es grande, entonces:

$$X \approx N(\lambda, \lambda)$$

o equivalentemente:

$$Z = \frac{X - \lambda}{\sqrt{\lambda}} \approx N(0, 1)$$

La aproximación es muy buena si $\lambda \geq 30$.

Fundamentación

Recordemos que si $X_i \sim P(1)$ i.i.d., entonces $\sum_{i=1}^n X_i \sim P(n)$

Por TCL: $\frac{X - \lambda}{\sqrt{\lambda}} \approx N(0, 1)$ cuando λ es grande.

Ejemplo: Aproximación Poisson a Normal

Problema

El número de clientes que llegan a un banco por hora sigue una distribución Poisson con $\lambda = 50$. ¿Cuál es la probabilidad de que lleguen menos de 70 clientes en una hora?

Solución:

- ▶ X = cantidad de clientes por hora, $X \sim P(50)$
- ▶ Verificación: $\lambda = 50 \geq 30$
- ▶ Aproximación: $X \approx N(50, 50)$

$$P(X < 70) = P\left(\frac{X - 50}{\sqrt{50}} < \frac{70 - 50}{\sqrt{50}}\right) \approx \Phi(2.828) = 0.9976$$

Comparación de las Tres Aproximaciones

Aspecto	TCL Promedio	Binomial	Poisson
Distribución	Cualquiera	$B(n, p)$	$P(\lambda)$
Condición	$n \geq 30$	$np \geq 5, n(1 - p) \geq 5$	$\lambda \geq 30$
Media	μ	np	λ
Varianza	σ^2/n	$np(1 - p)$	λ

Puntos clave comunes

- ▶ Todas se basan en el Teorema Central del Límite
- ▶ Mejoran cuando el n aumenta
- ▶ Para variables discretas mejora si se aplica corrección por continuidad