

Estadística - Estimación puntual

Agenda

Introducción

Estimación Puntual

Método de momentos

Máxima Verosimilitud

Estadística

La Estadística consiste de procedimientos para analizar información de carácter aleatorio.

En particular a partir de seleccionar un subconjunto de un gran conjunto de datos, la estadística permite inferir las características del conjunto completo.

Población y muestra

- ▶ **Población:** conjunto de todos los individuos o elementos individuales que es objetivo de nuestro interés,
- ▶ **Muestra:** subconjunto seleccionado de la población.
- ▶ **Censo:** Cuando la información deseada está disponible para todos los elementos de la población.

El censo puede ser poco práctico o inviable. La muestra se ajusta a las necesidades y recursos.

Etapas de la investigación

1. *Diseño*: Planeamiento y desarrollo de las investigaciones.
2. *Descripción*: Resumen y exploración de los datos.
3. *Inferencia*: Predicciones y/o toma de decisiones sobre las características de la población en base a la información recogida de la muestra.

Si la 1 no es correcta, podrían no poder hacerse inferencias.

Diseño

Se define cómo se desarrollará la investigación con el fin de responder las preguntas que le dieron origen

Una vez formulado el problema, en esta etapa se definirá:

- ▶ la población objetivo,
- ▶ los tamaños de muestra,
- ▶ los mecanismos de selección de individuos (muestreo),
- ▶ las variables que se medirán,
- ▶ cómo se entrenará al equipo de trabajo para el cumplimiento del protocolo,
- ▶ etc.

Muestreo aleatorio simple

A priori se conoce la probabilidad de que cada uno de los elementos de la población pertenezca a la muestra. Puede ser

- ▶ **con reemplazo:** donde todas las unidades poblacionales tienen la misma probabilidad de pertenecer a la muestra, pudiendo medirse varias veces el mismo individuo. (resultan variables aleatorias iid)
- ▶ **sin reemplazo:** el cual es igual al anterior ya que todos los individuos tienen idéntica probabilidad de pertenecer a la muestra, pero los individuos no pueden seleccionarse varias veces. (variables aleatoria no independientes)

En poblaciones grandes se pueden considerar equivalentes cuando el tamaño de la población (N) es grande y el tamaño de la muestra n es pequeño relativo a N (al menos $n/N \leq 0.05$)

Análisis Exploratorio

La *Estadística Descriptiva* ayuda a comprender la estructura de los datos mediante

- ▶ gráficos
- ▶ medidas resumen
- ▶ tablas

Explorar los datos permite detectar datos erróneos o inesperados y nos ayudará a decidir qué métodos estadísticos pueden ser empleados en etapas posteriores del análisis.

Inferencia Estadística

Permite hacer predicciones, estimaciones o decidir entre dos hipótesis opuestas relativas a la población de la cual provienen los datos (test de hipótesis).

Cuando inferimos no tenemos garantía de que la conclusión obtenida es exactamente correcta.

Sin embargo, para datos obtenidos a partir de muestras aleatorias, podemos cuantificar el error asociado a la estimación o calcular la probabilidad de cometer un error al tomar una decisión en un test de hipótesis.

Estimación Puntual

Muchas familias de distribuciones de probabilidad dependen de una pequeña cantidad de **parámetros**, por ejemplo

- ▶ la familia Poisson depende del parámetro λ (el número medio de recuentos)
- ▶ la familia gaussiana o normal depende de dos parámetros, μ y σ

Los valores de los parámetros a menudo no se conocen de antemano.

El objetivo de la estimación puntual es usar una muestra para obtener el número que, en algún sentido, sea el que mejor representa al verdadero valor del parámetro desconocido.

Notación

Sea $X \sim F_\theta$ con $\theta = (\theta_1, \dots, \theta_k)$ $k = 1, 2, \dots$

f_θ o $f(\cdot, \theta)$ denota a la función de densidad o frecuencia.

Muestra: n copias de $X \rightarrow \{X_1, X_2, \dots, X_n\}$, X_i es variable aleatoria, se llama **observación**

Valores observados: $\{x_1, x_2, \dots, x_n\}$, es decir $X_i = x_i \rightarrow x_i$ es un valor observado

Muestra aleatoria simple (m.a.): $X_1, X_2, \dots, X_n$ son i.i.d.

En general trabajaremos con muestras aleatorias simples salvo que se especifique lo contrario.

Estadístico

Definición

Un **estadístico** es una función de una muestra. Antes de observar los datos, existe incertidumbre del valor que cualquier estadístico puede tomar. Por consiguiente, un estadístico es una variable aleatoria y será denotada por una letra mayúscula; se utiliza una letra minúscula para representar el valor calculado u observado del estadístico.

Media muestral o promedio: $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \longrightarrow$ estadístico.

Una vez observada la muestra: $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \longrightarrow$ valor observado

Estimador puntual y estimación

Definición

Un **estimador puntual** de un parámetro θ es una función de $X_1, X_2, \dots, X_n$ que se utiliza para estimar el valor desconocido de ese parámetro y se indicará $\hat{\theta}$, de modo que un estimador es un estadístico y por lo tanto una variable aleatoria. Cuando esa función se aplica a los valores observados $x_1, x_2, \dots, x_n$ constituye una **estimación puntual**, que es un número.

Ejemplo

Enunciado

Se desea evaluar si un dado es equilibrado. Para ello se arrojó el dado 150 veces, y se observó que en 45 oportunidades salió un as. ¿Qué valor podría utilizarse, en base a esa información, como estimación de la probabilidad de as?

- ▶ **Objetivo:** Evaluar si el dado es equilibrado
- ▶ **Muestra:** 150 lanzamientos del dado
- ▶ **Observación:** 45 veces salió un “as” (número 1)
- ▶ **Variable de interés:** Número de ases obtenidos

Modelado Estadístico

$X =$ “Número de ases en 150 lanzamientos”

Descomposición en Variables Bernoulli

$$X = X_1 + X_2 + \cdots + X_{150}$$

donde para cada $i = 1, \dots, 150$:

$$X_i = \begin{cases} 1 & \text{si en el lanzamiento } i \text{ sale as} \\ 0 & \text{en caso contrario} \end{cases}$$

Cada $X_i \sim B(p) = B(1, p)$, donde:

$$P(X_i = 1) = p, \quad P(X_i = 0) = 1 - p$$

Parámetro Desconocido y Estimación

El **parámetro desconocido** es: p = probabilidad de obtener un as.
Tenemos $x = \sum_{i=1}^n x_i = 45$ (valor observado) y $n = 150$ (tamaño de la muestra de variables Bernoulli).

La frecuencia relativa de ases es

$$\hat{p} = \frac{45}{150} = 0.3.$$

Estimador Natural

$$\hat{p} = \frac{X}{n} = \frac{1}{n} \sum_{i=1}^n X_i$$

La probabilidad estimada de obtener un as ($\hat{p} = 0.3$) es aproximadamente **el doble** del valor esperado para un dado equilibrado ($p = 1/6 = 0.1667$), lo que parece indicar que el dado no está equilibrado.

Método de momentos

Observemos que la esperanza poblacional de X_i , EX_i , es una función de θ (no depende de i):

$$EX_i = \sum_{x \in C} xp(x|\theta) \quad \text{en el caso discreto}$$
$$= \int_{-\infty}^{\infty} xf(x|\theta)dx \quad \text{en el caso continuo.}$$

Sea X una variable aleatoria con la misma distribución que las X_i . Si la esperanza existe, definimos $m(\theta) = EX$.

Estimador de momentos

El **estimador de momentos** de θ es el valor $\hat{\theta}$ que se obtiene como solución de la ecuación

$$m(\theta) = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i,$$

es decir, igualando la media poblacional $m(\theta)$ con la media muestral $\bar{X}$.

Ejemplo

Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria de una distribución exponencial de parámetro λ .

Para encontrar el estimador de momentos $\hat{\lambda}$ tenemos que plantear la ecuación

$$m(\lambda) = \overline{X}. \quad (1)$$

Recordemos que

$$m(\lambda) = EX_i = \frac{1}{\lambda},$$

reemplazando en (1) obtenemos la ecuación $\frac{1}{\lambda} = \overline{X}$ y despejando λ ,

$$\hat{\lambda} = \frac{1}{\overline{X}}.$$

Estimador de momentos general

Se igualan las medias poblacional y muestral, no de las X_i sino de alguna función g de las mismas

$$Eg(X) = \frac{1}{n} \sum_{i=1}^n g(X_i). \quad (2)$$

Notar que distintas elecciones de g no necesariamente darán el mismo estimador.

Lo habitual es tomar $g(x) = x$, pero hay casos en que esa elección no sirve, y es mejor tomar, por ejemplo, g de la forma $g(x) = x^k$.

Ejemplo

Si $X_1, X_2, \dots, X_n$ son variables aleatorias i.i.d. con distribución $N(0, \sigma^2)$

Se desea estimar la varianza $\theta = \sigma^2$

$$m(\theta) = 0 \implies g(x) = x \text{ no sirve.}$$

Tomamos $g(x) = x^2$, la ecuación resultante es

$$EX_i^2 = \theta = \frac{1}{n} \sum_{i=1}^n X_i^2,$$

el cual resulta un estimador razonable.

Momentos

El nombre del método de momentos proviene de que

$$E(X^k)$$

es el **momento poblacional de orden k** y

$$\frac{1}{n} \sum_{i=1}^n x_i^k$$

es el **momento muestral de orden k** .

m parámetros

Si $X_1, X_2, \dots, X_n$ son variables aleatorias i.i.d con distribución

$$F_{(\theta_1, \dots, \theta_m)}.$$

Los estimadores de momentos de $\theta_1, \dots, \theta_m$ son los valores $\hat{\theta}_1, \dots, \hat{\theta}_m$ que se obtienen igualando m momentos poblacionales con sus correspondientes momentos muestrales.

En general, se obtienen resolviendo el siguiente sistema de ecuaciones

$$EX^k = \frac{1}{n} \sum_{i=1}^n X_i^k \quad k = 1, \dots, m. \quad (3)$$

Ejemplo

Sea $X_1, X_2, \dots, X_n$ i.i.d con distribución $N(\mu, \sigma^2)$.

Sea $\theta_1 = \mu$ y $\theta_2 = \sigma^2$

El primer y segundo momento de la distribución normal son

$$EX = \mu \quad y \quad EX^2 = \mu^2 + \sigma^2$$

Reemplazando en (3) tenemos el sistema

$$\theta_1 = \bar{X}$$

$$\theta_1^2 + \theta_2 = \frac{1}{n} \sum_{i=1}^n X_i^2$$

Luego, despejando

$$\hat{\theta}_1 = \bar{X} \quad y \quad \hat{\theta}_2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Método de máxima verosimilitud

Dadas $X_1, X_2, \dots, X_n$ variables aleatorias i.i.d. con distribución F_θ , la **función de verosimilitud** es la función de frecuencia o de densidad conjunta de las observaciones, es decir,

$$L(x_1, \dots, x_n | \theta) = \prod_{i=1}^n p(x_i | \theta) \quad \text{para } x_i \in C$$

en el caso discreto

$$= \prod_{i=1}^n f(x_i | \theta)$$

en el caso continuo.

Sea $\Theta = \{\theta : F_\theta \text{ está bien definida}\}$

Método de máxima verosimilitud

La **estimación de máxima verosimilitud** de θ es el valor de

$$\hat{\theta} = \hat{\theta}(x_1, \dots, x_n) \in \Theta$$

que maximiza la función de verosimilitud

$$L(x_1, \dots, x_n; \theta),$$

osea el valor tal que

$$L(x_1, \dots, x_n | \hat{\theta}) \geq L(x_1, \dots, x_n | \hat{\theta})$$

para todo $\hat{\theta} \in \Theta$.

Se llama **estimador de máxima verosimilitud** (EMV) al estadístico calculado en base a la muestra aleatoria, es decir,

$$\hat{\theta}(X_1, \dots, X_n).$$

Espacio de los parámetros

Un solo parámetro desconocido $\longrightarrow \Theta \subset \mathbb{R}$

- ▶ $X \sim \text{Exp}(\lambda)$, $\lambda > 0$ $\Theta = (0, +\infty)$

Más de un parámetro desconocido, por ejemplo m , $\Theta \subset \mathbb{R}^m$,
 $\longrightarrow$ tienen que encontrarse los m valores que maximizan la función de verosimilitud.

- ▶ $X \sim N(\mu, \sigma^2)$, $\theta = (\mu, \sigma^2)$, $\mu \in \mathbb{R}$ y $\sigma^2 > 0$ entonces $\Theta \subset \mathbb{R}^2$
y $\Theta = \mathbb{R} \times (0, +\infty)$

Ejemplo

Sea $X_1, X_2, \dots, X_n$ una m.a. de una distribución $Exp(\lambda)$.

Función de verosimilitud:

$$\begin{aligned} L(x_1, \dots, x_n | \lambda) &= \prod_{i=1}^n f(x_i | \lambda) = \prod_{i=1}^n \lambda e^{-\lambda x_i} \\ &= \lambda^n e^{\{-\lambda \sum_{i=1}^n x_i\}}. \end{aligned}$$

Calculando $\frac{dL}{d\lambda}$, la derivada de L con respecto a λ e igualando a cero, tenemos que

$$n\lambda^{n-1} e^{\{-\lambda \sum_{i=1}^n x_i\}} - \lambda^n e^{\{-\lambda \sum_{i=1}^n x_i\}} \sum_{i=1}^n x_i = 0$$

Ejemplo

Luego de verificar que en el punto crítico obtenido en efecto se alcanza un máximo (se puede usar criterio de la segunda derivada). Se tiene que el EMV de λ es

$$\hat{\lambda} = \frac{n}{\sum_{i=1}^n X_i} = \frac{1}{\bar{X}}.$$

Observemos que en este caso el EMV coincide con el de momentos.

Caso regular

En la mayoría de las situaciones, el conjunto

$$C = \{x : f(x, \theta) > 0\} \circ C = \{x : p(x, \theta) > 0\}$$

no depende de θ .

Por ejemplo, para la normal es $C = \mathbb{R}$, y para $Exp(\lambda)$ es $C = \mathbb{R}_+$ para todo $\lambda > 0$. Esto se llama el **caso regular**.

En estos casos, como las sumas suelen ser más tratables que los productos, una forma conveniente de obtener el EMV es maximizar el logaritmo de la función de verosimilitud L , lo que es equivalente a maximizar L por ser el logaritmo una función creciente.

Ejemplo distribución Normal

Sea $X_1, X_2, \dots, X_n$ una m.a. de una distribución $N(\mu, \sigma^2)$.

Se desea encontrar los EMV de μ y σ siendo $f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$.

Maximizaremos el $\ln$ de la función de verosimilitud L :

$$\begin{aligned}\ln L(x_1, \dots, x_n | \mu, \sigma) &= \ln \left[\left(\frac{1}{\sqrt{2\pi}} \right)^n \frac{1}{\sigma^n} e^{\left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right\}} \right] \\ &= -n \ln(\sqrt{2\pi}) - n \ln(\sigma) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\end{aligned}$$

Derivando con respecto a μ (tomando como constante σ) e igualando a cero, tenemos que

$$\sum_{i=1}^n (x_i - \mu) = 0 \quad (4)$$

Ejemplo distribución Normal

Derivando con respecto a σ (tomando como constante μ) e igualando a cero, tenemos que

$$-n\sigma^2 + \sum_{i=1}^n (x_i - \mu)^2 = 0. \quad (5)$$

Despejando μ y σ de (4) y (5) se obtiene que los EMV de μ y σ son

$$\hat{\mu} = \bar{X}$$

$$\hat{\sigma} = \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2}.$$

Propiedad de Invarianza

Propiedad

Sea $\hat{\theta}$ el EMV de θ y sea h una función inyectiva con dominio en el rango de valores posibles de θ , entonces el EMV de $h(\theta)$ es $h(\hat{\theta})$.
El método de momentos posee la misma propiedad.

Ejemplo

Para una m.a. de una distribución $N(\mu, \sigma^2)$ vimos que el EMV de σ es

$$\hat{\sigma} = \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2}$$

entonces el EMV de σ^2 es

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

pues la función $h(x) = x^2$ es inyectiva si su dominio se restringe a los reales positivos.