

Estimación puntual

Agenda

Repaso

Comparación de estimadores

MUESTRA



La **variable estadística** es la **propiedad o característica** de la **población** que estamos interesados en estudiar.

La población se refiere al grupo total de individuos o elementos bajo estudio.

Este grupo puede ser delimitado mediante métodos de selección aleatoria teniendo en cuenta características específicas.

El análisis de la muestra permite obtener conclusiones representativas para la población.

Muestra

Sea $X \sim F_\theta$ con $\theta = (\theta_1, \dots, \theta_k)$ $k = 1, 2, \dots$
 f_θ o $f(\cdot, \theta)$ denota a la función de densidad o frecuencia.

Muestra: n copias de $X \rightarrow \{X_1, X_2, \dots, X_n\}$, X_i es variable aleatoria, se llama **observación**

Valores observados: $\{x_1, x_2, \dots, x_n\}$, es decir $X_i = x_i \rightarrow x_i$ es un valor observado

Muestra aleatoria simple (m.a.): $X_1, X_2, \dots, X_n$ son i.i.d.

En general trabajaremos con muestras aleatorias simples salvo que se especifique lo contrario.

Estadístico

Definición

Un **estadístico** es una función de una muestra. Antes de observar los datos, existe incertidumbre del valor que cualquier estadístico puede tomar. Por consiguiente, un estadístico es una variable aleatoria y será denotada por una letra mayúscula; se utiliza una letra minúscula para representar el valor calculado u observado del estadístico.

Media muestral o promedio: $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \longrightarrow$ estadístico.

Una vez observada la muestra: $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \longrightarrow$ valor observado

Estimador puntual y estimación

Definición

Un **estimador puntual** de un parámetro θ es una función de $X_1, X_2, \dots, X_n$ que se utiliza para estimar el valor desconocido de ese parámetro y se indicará $\hat{\theta}$, de modo que un estimador es un estadístico y por lo tanto una variable aleatoria. Cuando esa función se aplica a los valores observados $x_1, x_2, \dots, x_n$ constituye una **estimación puntual**, que es un número.

Método de momentos

Sea X una variable aleatoria con la misma distribución que las X_i . Si la esperanza existe, definimos $m(\theta) = EX$. El **estimador de momentos** de θ es el valor $\hat{\theta}$ que se obtiene como solución de la ecuación

$$m(\theta) = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i,$$

es decir, igualando la media poblacional $m(\theta)$ con la media muestral $\bar{X}$.

m parámetros

Si $X_1, X_2, \dots, X_n$ son variables aleatorias i.i.d con distribución

$$F_{(\theta_1, \dots, \theta_m)}.$$

Los estimadores de momentos de $\theta_1, \dots, \theta_m$ son los valores $\hat{\theta}_1, \dots, \hat{\theta}_m$ que se obtienen igualando m momentos poblacionales con sus correspondientes momentos muestrales.

En general, se obtienen resolviendo el siguiente sistema de ecuaciones

$$EX^k = \frac{1}{n} \sum_{i=1}^n X_i^k \quad k = 1, \dots, m. \quad (1)$$

Método de máxima verosimilitud

Dadas $X_1, X_2, \dots, X_n$ variables aleatorias i.i.d. con distribución F_θ , la **función de verosimilitud** es la función de frecuencia o de densidad conjunta de las observaciones, es decir,

$$L(x_1, \dots, x_n | \theta) = \prod_{i=1}^n p(x_i | \theta) \quad \text{para } x_i \in \mathcal{C}$$

en el caso discreto

$$= \prod_{i=1}^n f(x_i | \theta)$$

en el caso continuo.

Sea $\Theta = \{\theta : F_\theta \text{ está bien definida}\}$

Método de máxima verosimilitud

La **estimación de máxima verosimilitud** de θ es el valor de

$$\hat{\theta} = \hat{\theta}(x_1, \dots, x_n) \in \Theta$$

que maximiza la función de verosimilitud

$$L(x_1, \dots, x_n; \theta),$$

osea el valor tal que

$$L(x_1, \dots, x_n | \hat{\theta}) \geq L(x_1, \dots, x_n | \hat{\theta})$$

para todo $\hat{\theta} \in \Theta$.

Se llama **estimador de máxima verosimilitud** (EMV) al estadístico calculado en base a la muestra aleatoria, es decir,

$$\hat{\theta}(X_1, \dots, X_n).$$

Caso regular

En la mayoría de las situaciones, el conjunto

$$C = \{x : f(x, \theta) > 0\} \circ C = \{x : p(x, \theta) > 0\}$$

no depende de θ .

Por ejemplo, para la normal es $C = \mathbb{R}$, y para $Exp(\lambda)$ es $C = \mathbb{R}_+$ para todo $\lambda > 0$. Esto se llama el **caso regular**.

En estos casos, como las sumas suelen ser más tratables que los productos, una forma conveniente de obtener el EMV es maximizar el logaritmo de la función de verosimilitud L , lo que es equivalente a maximizar L por ser el logaritmo una función creciente.

Caso normal: $X_1, X_2, \dots, X_n$ i.i.d con distribución $N(\mu, \sigma^2)$.

Vimos que para esta distribución el estimador de momentos coincide con el de máxima verosimilitud.

$$\hat{\mu} = \bar{X} \quad y \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Por la Propiedad de Invarianza

Propiedad

Si $\hat{\theta}$ es el EMV o de momentos de θ y h es una función inyectiva con dominio en el rango de valores posibles de θ , entonces el EMV o de momentos (respectivamente) de $h(\theta)$ es $h(\hat{\theta})$.

$$\hat{\sigma} = \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2}$$

Error Cuadrático Medio

Dada una muestra aleatoria $X_1, X_2, \dots, X_n$, donde $X_i \sim F(\cdot|\theta)$,

$$\hat{\theta} = \theta + \text{error de estimación} \longrightarrow v.a.$$

Un estimador preciso sería uno que produzca errores de estimación pequeños

Definición

El error cuadrático medio (ECM) de un estimador $\hat{\theta}$ es $E(\hat{\theta} - \theta)^2$.

Principio de estimación de menor error cuadrático medio

Si un primer estimador tiene un EMC más pequeño que un segundo, es natural decir que el primer estimador es el mejor. Basados en este criterio, el mejor estimador $\hat{\theta}$ para θ es aquel que minimiza el ECM (Principio de estimación de menor error cuadrático medio).

Sesgo

Recordemos para reescribir el ECM:

$$V(Y) = EY^2 - (EY)^2,$$

despejando EY^2 obtenemos

$$E(Y^2) = V(Y) + (EY)^2.$$

Tomando $Y = \hat{\theta} - \theta$, el lado izquierdo es el ECM.

$$V(Y) = V(\hat{\theta} - \theta) = V(\hat{\theta})$$

y $E(Y) = E\hat{\theta} - \theta$ representa la diferencia entre el valor esperado del estimador y el valor del parámetro. Se llama **sesgo** del estimador. Luego,

$$ECM(\hat{\theta}) = V(\hat{\theta}) + (E\hat{\theta} - \theta)^2 = \text{varianza del estimador} + (\text{sesgo})^2.$$

Estimador insesgado

Definición

Un estadístico $\hat{\theta}$ es un estimador **insesgado** del parámetro θ de una distribución dada si y solo si $E(\hat{\theta}) = \theta$ para todos los valores posibles de θ .

Todo estimador insesgado de θ satisfacen que su ECM es igual a su varianza, de lo que se deduce el **Principio de estimación insesgada de mínima varianza**. Este criterio consiste en elegir de entre todos los estimadores insesgados de θ aquel de menor varianza. El estimador resultante se denomina IMVU (insesgado de mínima varianza uniformemente).

Ejemplo

Recordemos que para una m.a. $X_1, X_2, \dots, X_n$ de una distribución $N(\mu, \sigma^2)$, los EMV y de momentos de μ y σ^2 son

$$\hat{\mu} = \bar{X} \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Como la $EX_i = \mu$ para todo i ,

$$E\bar{X} = \frac{1}{n} E \sum_{i=1}^n X_i = \frac{1}{n} \sum_{i=1}^n EX_i = \frac{1}{n} \sum_{i=1}^n \mu = \mu,$$

luego $\hat{\mu}$ es un estimador inesegado de μ .

Ejemplo

En cuanto a $\hat{\sigma}^2$ recordemos que puede escribirse como

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \left(\frac{1}{n} \sum_{i=1}^n X_i^2 \right) - \bar{X}^2$$

$$E(\hat{\sigma}^2) = \left(\frac{1}{n} \sum_{i=1}^n E(X_i^2) \right) - E(\bar{X}^2).$$

Como las variables son *i.i.d.*, $E\bar{X} = \mu$ y $V(\bar{X}) = \sigma^2/n$,
 $E(X_i^2) = \sigma^2 + \mu^2$ y $E(\bar{X}^2) = \sigma^2/n + \mu^2$, luego

$$E(\hat{\sigma}^2) = \frac{1}{n} n(\sigma^2 + \mu^2) - \left(\frac{\sigma^2}{n} + \mu^2 \right) = \frac{n-1}{n} \sigma^2.$$

Por lo tanto $\hat{\sigma}^2$ no es inesgado.

Varianza muestral

Ahora bien, si se considera el estimador

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

como estimador de la varianza σ^2 , se llega a que éste estimador si es inesegado.

Ya que

$$E(S^2) = E\left(\frac{n}{n-1} \hat{\sigma}^2\right) = \frac{n}{n-1} \frac{n-1}{n} \sigma^2 = \sigma^2.$$

Al estimador S^2 se lo llama **varianza muestral**.

IMVU de la Normal

Repitiendo las cuentas del ejemplo, se puede probar la siguiente proposición

Proposición

Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria de una distribución con media μ y varianza σ^2 . Los estimadores $\bar{X}$ y S^2 son insesgados para μ y σ^2 , respectivamente.

Dada una muestra aleatoria $X_1, X_2, \dots, X_n$ de una distribución $N(\mu, \sigma^2)$, $\bar{X}$ es un estimador IMVU de μ (no veremos la demostración).

Eficiencia relativa

Definición

Dados dos estimadores insesgados $\hat{\theta}_1$ y $\hat{\theta}_2$ de un parámetro θ , con varianzas $V(\hat{\theta}_2)$ y $V(\hat{\theta}_1)$, respectivamente, entonces la **eficiencia** de $\hat{\theta}_1$ con respecto a $\hat{\theta}_2$, denotada $\text{efr}(\hat{\theta}_1, \hat{\theta}_2)$, se define como la razón

$$\text{efr}(\hat{\theta}_1, \hat{\theta}_2) = \frac{V(\hat{\theta}_2)}{V(\hat{\theta}_1)}.$$

Si $\hat{\theta}_1$ y $\hat{\theta}_2$ son estimadores insesgados para θ y $\text{efr}(\hat{\theta}_1, \hat{\theta}_2) > 1$, entonces $\hat{\theta}_1$ es más eficiente que $\hat{\theta}_2$.

Ejemplo

Sea $X_1, X_2, \dots, X_n$ una m.a. de una distribución $N(\mu, \sigma^2)$.
Consideremos los siguientes estimadores de μ :

$$\hat{\mu}_1 = \bar{X} \quad \text{y} \quad \hat{\mu}_2 = X_1.$$

Ambos son insesgados, ya que $E\bar{X} = \mu$ y $EX_1 = \mu$.
Sus varianzas son

$$V(\hat{\mu}_1) = \frac{\sigma^2}{n} \quad \text{y} \quad V(\hat{\mu}_2) = \sigma^2.$$

Luego

$$\text{efr}(\hat{\mu}_1, \hat{\mu}_2) = \frac{\sigma^2}{\sigma^2/n} = n > 1 \quad \text{para} \quad n > 1.$$

Consistencia

Definición

Una secuencia de estimadores puntuales $\hat{\theta}_n$ del parámetro θ basados en una muestra aleatoria $X_1, X_2, \dots, X_n$ de una distribución dada, es **consistente** en probabilidad para θ si y solo si para todo $\epsilon > 0$,

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| < \epsilon) = 1.$$

Teorema

Teorema

Si $\hat{\theta}_n$ es una secuencia de estimadores puntuales de θ tal que

- ▶ $\hat{\theta}$ es un estimador **insesgado** del parámetro θ ($E(\hat{\theta}_n) = \theta$)
- ▶ $\lim_{n \rightarrow \infty} V(\hat{\theta}_n) = 0$,

entonces $\hat{\theta}_n$ es consistente para θ .

Ejemplo

Sea $X_1, X_2, \dots, X_n$ una m.a. con media μ y varianza σ^2 .
Consideremos el estimador $\bar{X}$ de μ .

$$E\bar{X} = \mu \quad \text{y} \quad V(\bar{X}) = \frac{\sigma^2}{n} \rightarrow 0 \quad \text{cuando} \quad n \rightarrow \infty.$$

Por lo tanto $\bar{X}$ es consistente para μ .

Resumen para la Media Muestral

Definición

La **media muestral** se define como:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

Propiedades

- ▶ Es un estimador insesgado de $E(X) = \mu$: $E(\bar{X}) = \mu$
- ▶ Varianza: $V(\bar{X}) = \frac{\sigma^2}{n}$
- ▶ Es un estimador consistente para $E(X) = \mu$ (Ley de los Grandes Números).

Resumen para la Varianza Muestral

Definición

La **varianza muestral** se define como:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

Propiedades

- Es un estimador insesgado de σ^2 : $E(S^2) = \sigma^2$

El **desvío estándar muestral** se define como:

$$S = \sqrt{S^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$$

Ejemplo Numérico

Muestra: 4, 7, 5, 8, 6

- ▶ $n = 5$
- ▶ $\sum x_i = 4 + 7 + 5 + 8 + 6 = 30$
- ▶ $\sum x_i^2 = 16 + 49 + 25 + 64 + 36 = 190$

$$\bar{x} = \frac{30}{5} = 6$$

$$s^2 = \left(\frac{1}{n-1} \sum_{i=1}^n x_i^2 \right) - \frac{n}{n-1} \bar{x}^2 = \frac{190}{4} - \frac{6^2}{4} \times 5 = 2.5$$

$$s = \sqrt{2.5} \approx 1.581$$