

Intervalos de Confianza para la diferencia de medias

Agenda

Repaso

IC para la diferencia de medias con varianzas desconocidas

IC para la diferencia de medias (muestras pareadas)

Introducción: Comparación de Dos Medias

Problema de interés

Comparar las medias μ_1 y μ_2 de dos poblaciones normales independientes:

$$\begin{cases} X \sim N(\mu_1, \sigma_1^2) \\ Y \sim N(\mu_2, \sigma_2^2) \end{cases}$$

De las que se obtiene dos muestras:

- ▶ Muestra 1: $X_1, X_2, \dots, X_{n_1}$ de X
- ▶ Muestra 2: $Y_1, Y_2, \dots, Y_{n_2}$ de Y
- ▶ Muestras independientes entre sí

Objetivo: Construir un intervalo de confianza para $\mu_1 - \mu_2$

Casos a considerar

1. Varianzas conocidas
2. Varianzas desconocidas pero iguales ($\sigma_1^2 = \sigma_2^2$)
3. Varianzas desconocidas y distintas

Caso 1: Varianzas Conocidas

$X_1, X_2, \dots, X_{n_1}$ y $Y_1, Y_2, \dots, Y_{n_2}$ **independientes** entre sí

Supuestos

- ▶ $X_i \sim N(\mu_1, \sigma_1^2)$ para $i = 1, \dots, n_1$,
- ▶ $Y_j \sim N(\mu_2, \sigma_2^2)$ para $j = 1, \dots, n_2$.
- ▶ σ_1^2 y σ_2^2 conocidas
- ▶ Muestras independientes

Estadísticos muestrales:

$$\bar{X} = \frac{1}{n_1} \sum_{i=1}^{n_1} X_i, \quad \bar{Y} = \frac{1}{n_2} \sum_{i=1}^{n_2} Y_i$$

Caso 1: Varianzas Conocidas

Usando que $\bar{X}$ y $\bar{Y}$ son independientes, se sabe que

$$\left. \begin{array}{l} \bar{X} \sim N\left(\mu_1, \frac{\sigma_1^2}{n_1}\right) \\ \bar{Y} \sim N\left(\mu_2, \frac{\sigma_2^2}{n_2}\right) \end{array} \right\} \Rightarrow \bar{X} - \bar{Y} \sim N\left(\mu_1 - \mu_2, \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}\right).$$

Pivote:

$$Z = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1)$$

Intervalo para Varianzas Conocidas

Del pivote $Z \sim N(0, 1)$, planteamos:

$$P(-z_{\alpha/2} \leq Z \leq z_{\alpha/2}) = 1 - \alpha$$

Sustituyendo:

$$P\left(-z_{\alpha/2} \leq \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \leq z_{\alpha/2}\right) = 1 - \alpha$$

y despejando $\mu_1 - \mu_2$ obtenemos:

Intervalo de confianza de nivel $(1 - \alpha)$ para $\mu_1 - \mu_2$

$$\left[(\bar{X} - \bar{Y}) - z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}, (\bar{X} - \bar{Y}) + z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right]$$

Muestras Grandes: TCL y Varianza Conocida

Teorema Central del Límite (TCL)

Para muestras grandes ($n_1 \geq 30$ y $n_2 \geq 30$) de **cualquier distribución** con medias μ_1 y μ_2 y varianzas σ_1^2 y σ_2^2 conocidas: Usando que $\bar{X}$ y $\bar{Y}$ son independientes, se sabe que

$$\left. \begin{array}{l} \bar{X} \approx N\left(\mu_1, \frac{\sigma_1^2}{n_1}\right) \\ \bar{Y} \approx N\left(\mu_2, \frac{\sigma_2^2}{n_2}\right) \end{array} \right\} \Rightarrow \bar{X} - \bar{Y} \approx N\left(\mu_1 - \mu_2, \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}\right).$$

Equivalentemente:

$$Z = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \approx N(0, 1)$$

Intervalo de confianza para la media de nivel aproximado

Si $n_1 \geq 30$ y $n_2 \geq 30$, usando TCL tenemos que

$$1 - \alpha \approx P \left[-z_{\alpha/2} \leq \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \leq z_{\alpha/2} \right].$$

Despejando:

Intervalo de confianza de **nivel aproximadamente** $(1 - \alpha)$
para $\mu_1 - \mu_2$

$$\left[(\bar{X} - \bar{Y}) - z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}, (\bar{X} - \bar{Y}) + z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right]$$

Caso 2: Varianzas Desconocidas pero Iguales

$X_1, X_2, \dots, X_{n_1}$ y $Y_1, Y_2, \dots, Y_{n_2}$ **independientes** entre sí

Supuestos

- ▶ $X_i \sim N(\mu_1, \sigma_1^2)$ para $i = 1, \dots, n_1$,
- ▶ $Y_j \sim N(\mu_2, \sigma_2^2)$ para $j = 1, \dots, n_2$.
- ▶ $\sigma_1^2 = \sigma_2^2 = \sigma^2$ desconocida
- ▶ Muestras independientes

Estimador combinado de la varianza:

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

donde S_1^2 y S_2^2 son las varianzas muestrales obtenidas con la muestra $X_1, X_2, \dots, X_{n_1}$ y $Y_1, Y_2, \dots, Y_{n_2}$, respectivamente.

Intervalo para Varianzas Iguales

Propiedad:

S_p^2 es estimador insesgado de σ^2 : $E(S_p^2) = \sigma^2$.

Pivote:

$$T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t_{n_1+n_2-2}$$

donde $t_{n_1+n_2-2}$ representa la distribución t de Student con $n_1 + n_2 - 2$ grados de libertad.

Del pivote $T \sim t_{n_1+n_2-2}$, planteamos:

$$P(-t_{\alpha/2, n_1+n_2-2} \leq T \leq t_{\alpha/2, n_1+n_2-2}) = 1 - \alpha$$

Intervalo para Varianzas Iguales

Sustituyendo:

$$P \left(-t_{\alpha/2, n_1+n_2-2} \leq \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \leq t_{\alpha/2, n_1+n_2-2} \right) = 1 - \alpha$$

y despejando $\mu_1 - \mu_2$ obtenemos:

Intervalo de confianza de nivel $(1 - \alpha)$ para $\mu_1 - \mu_2$

$$(\bar{X} - \bar{Y}) \pm t_{\alpha/2, n_1+n_2-2} \cdot S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$$

donde $t_{\alpha/2, \nu}$ es el valor crítico de la distribución t-Student con ν grados de libertad y $\nu = n_1 + n_2 - 2$ son los grados de libertad en este caso (el valor de $t_{\alpha/2, n_1+n_2-2}$ se obtiene por tabla o app)

Ejemplo

El objetivo de un estudio de aptitud física fue determinar los resultados del ejercicio por un tiempo prolongado en los ejecutivos de una compañía inscriptos en un programa supervisado de acondicionamiento físico.

Se registraron datos de 13 individuos (el grupo deportista) que voluntariamente se inscribieron al programa y que permanecieron activos por 13 años en promedio, y de 17 individuos (el segundo grupo, el sedentario) que decidieron no inscribirse. Entre los datos que se registraron acerca de los individuos está el número máximo de sentadillas realizadas en 30 segundos.

El grupo deportista obtuvo una media y una desviación estándar de 21.0 y 4.9, respectivamente. La media y desviación estándar para el grupo sedentario fueron 12.1 y 5.6 respectivamente.

Ejemplo

Se considera que las dos poblaciones de mediciones de acondicionamiento muscular siguen una distribución normal, y que las varianzas para ambas poblaciones son iguales.

Se pretende elaborar un intervalo del 98 % para la diferencias entre las medias de las poblaciones representadas por las dos muestras.

Modelización Ejemplo

Tenemos dos muestras aleatorias:

- ▶ $X_1, X_2, \dots, X_{n_1}$ con tamaño muestral $n_1 = 13$, con cada $X_i \sim N(\mu_1, \sigma^2)$
 X_i indica el número máximo de sentadillas realizadas en 30 segundos por el individuo i del grupo deportista;
- ▶ $Y_1, Y_2, \dots, Y_{n_2}$ con tamaño muestral $n_2 = 17$ y con cada $Y_i \sim N(\mu_2, \sigma^2)$,
 Y_i indica el número máximo de sentadillas realizadas en 30 segundos por el individuo i del grupo sedentario.

Las variables aleatorias X_i y Y_i son independientes.

IC Ejemplo

El intervalo de confianza para la diferencia de medias viene dado por

$$\left[\bar{X} - \bar{Y} \pm t_{\alpha/2, n_1+n_2-2} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right].$$

Nivel de confianza: 98 % ($\alpha = 0.02$)

Grados de libertad: $\nu = n_1 + n_2 - 2 = 13 + 17 - 2$

Valor crítico: $t_{\alpha/2, n_1+n_2-2} = t_{0.01, 28} = 2.4671$.

Estadísticos:

- ▶ $\bar{x} = 21$ $s_1 = 4.9$
- ▶ $\bar{y} = 12.1$ $s_2 = 5.6$

$$s_p^2 = \frac{(13-1) \cdot 4.9^2 + (17-1) \cdot 5.6^2}{13+17-2}$$

IC Ejemplo

Así,

$$\left[21 - 12.1 \pm 2.4671 \sqrt{\frac{(13 - 1) \cdot 4.9^2 + (17 - 1) \cdot 5.6^2}{13 + 17 - 2}} \sqrt{\left(\frac{1}{13} + \frac{1}{17} \right)} \right].$$

Por tanto,

$$IC_{0.98}(\mu_1 - \mu_2) = [4.0722, 13.7279].$$

Interpretación

Con 98 % de confianza, la diferencia entre las medias del número máximo de sentadillas está entre 4.0722 y 13.7279.

Como el intervalo no contiene al cero, hay evidencia de que el grupo de deportista en media puede realizar más sentadillas que el grupo sedentario.

Caso 3: Varianzas Desconocidas y Distintas

$X_1, X_2, \dots, X_{n_1}$ y $Y_1, Y_2, \dots, Y_{n_2}$ **independientes** entre sí

Supuestos

- ▶ $X_i \sim N(\mu_1, \sigma_1^2)$ para $i = 1, \dots, n_1$,
- ▶ $Y_j \sim N(\mu_2, \sigma_2^2)$ para $j = 1, \dots, n_2$.
- ▶ σ_1^2 y σ_2^2 desconocidas
- ▶ Muestras independientes

Pivote:

$$T^* = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}} \approx t_\nu$$
$$\nu = \frac{\left(\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}\right)^2}{\frac{(S_1^2/n_1)^2}{n_1-1} + \frac{(S_2^2/n_2)^2}{n_2-1}}$$

Grados de libertad: $\nu =$

Intervalo para Varianzas Distintas

Intervalo de confianza de nivel aproximado $(1 - \alpha)$ para $\mu_1 - \mu_2$

$$\left[(\bar{X} - \bar{Y}) - t_{\alpha/2, \nu} \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}, (\bar{X} - \bar{Y}) + t_{\alpha/2, \nu} \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}} \right]$$

donde:

$$\nu = \frac{\left(\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2} \right)^2}{\frac{(S_1^2/n_1)^2}{n_1-1} + \frac{(S_2^2/n_2)^2}{n_2-1}}$$

Nota: Si ν no es entero, se toma el entero más cercano.

Ejemplo

Para realizar un estudio sobre la hipertensión y sus consecuencias, se toman dos muestras de 13 y 16 pacientes de ciudades distintas y se midió la presión arterial de cada paciente. Los datos muestrales obtenidos fueron los siguientes:

$$\bar{x}_1 = 166 \text{ mm.} \quad s_1 = 28 \text{ mm.}$$

$$\bar{x}_2 = 164.7 \text{ mm.} \quad s_2 = 7 \text{ mm.}$$

Se considera que ambas poblaciones son Normales y que sus varianzas son desconocidas y distintas, se quiere determinar un intervalo de confianza al 95 % para la diferencia de medias.

Modelización Ejemplo

Tenemos dos muestras aleatorias:

- ▶ $X_1, X_2, \dots, X_{n_1}$ con tamaño muestral $n_1 = 13$, con cada $X_i \sim N(\mu_1, \sigma_1^2)$
 X_i = presión arterial del individuo i de la ciudad 1;
- ▶ $Y_1, Y_2, \dots, Y_{n_2}$ con tamaño muestral $n_2 = 16$ y con cada $Y_i \sim N(\mu_2, \sigma_2^2)$,
 Y_i = presión arterial del individuo i de la ciudad 2.

Las variables aleatorias X_i y Y_i son independientes.

Ejemplo

$$\begin{aligned}\nu &= \frac{\left(\frac{28^2}{13} + \frac{7^2}{16}\right)^2}{\frac{1}{12} \left(\frac{28^2}{13}\right)^2 + \frac{1}{15} \left(\frac{7^2}{16}\right)^2} \\ &= 13.4.\end{aligned}$$

Tomamos $\nu = 13$ y buscamos en tabla, luego

$t_{\alpha/2, \nu} = t_{0.025, 13} = 2.16$. Finalmente, el intervalo buscado es

$$\begin{aligned}IC_{0.95}(\mu_1 - \mu_2) &= \left[166 - 164.7 \pm 2.16 \sqrt{\frac{784}{13} + \frac{49}{16}} \right] \\ &= [-15.89, 18.49].\end{aligned}$$

Muestras pareadas

Se dice que dos muestras $X_1, X_2, \dots, X_n$ e $Y_1, Y_2, \dots, Y_n$ están **pareadas** cuando los datos de las muestras vienen por parejas, uno de cada una de ellas, es decir:

$$(X_1, Y_1), \dots, (X_n, Y_n).$$

Corresponde al caso en que de un mismo individuo u objeto se obtienen dos observaciones.

Ejemplo

Para estudiar los efectos de un determinado fármaco para adelgazar, se selecciona aleatoriamente 6 personas y se toma nota de sus pesos antes y después de administrarles el medicamento.

Antes	72.0	73.5	70.0	71.5	76.0	80.5
Después	73.0	74.5	74.0	74.5	75.0	82.0

Como puede observarse, los datos vienen por parejas: peso antes y después, dos datos por individuo.

Parece lógico que los datos se encuentren relacionados entre sí.

IC para la diferencia de medias (muestras pareadas)

Un planteo simplificado es suponer que el efecto de la diferencia de “métodos” es aditivo:

$$D_i = X_i - Y_i.$$

Si las $D_i \sim F$ para todo i , y por lo tanto

$$ED_i = \mu_1 - \mu_2$$

representa el “efecto medio” de la diferencia de métodos, el problema se reduce a encontrar un intervalo de confianza para la media de una población.

IC para la diferencia de medias (muestras pareadas)

Observar que no hace falta que las X_i ni las Y_i sean idénticamente distribuidas.

Un planteo simplificado es que

$$D_i \sim N(\mu_1 - \mu_2, \sigma^2).$$

Luego, los intervalos de confianza para $\mu_1 - \mu_2$ se obtienen a partir de las D_i con la metodología ya conocida de intervalos para la media de una distribución normal.

Ejemplo (continuación)

Asumimos que

$$D_i = X_i - Y_i \sim N(\mu_1 - \mu_2, \sigma^2),$$

siendo $X_1, X_2, \dots, X_n$ los pesos antes del tratamiento y $Y_1, Y_2, \dots, Y_n$ los pesos después del mismo.

Así, los valores de la nueva muestra D de tamaño $n = 6$ son

$$-1 \quad -1 \quad -4 \quad -3 \quad 1 \quad -1.5,$$

cuya media muestral es $\bar{d} = -1.58$ y su varianza muestral $s_d^2 = 3.04$.

IC Ejemplo

El intervalo de confianza para la diferencia de medias viene dado por

$$IC_{1-\alpha}(\mu_1 - \mu_2) = \left[\bar{D} - t_{\frac{\alpha}{2}, n-1} \frac{S_D}{\sqrt{n}}, \bar{D} + t_{\frac{\alpha}{2}, n-1} \frac{S_D}{\sqrt{n}} \right].$$

Para $\alpha = 0.05$, se tiene $t_{\frac{\alpha}{2}, n-1} = t_{0.025, 5} = 2.57$ y el intervalo queda

$$\begin{aligned} IC_{0.95}(\mu_1 - \mu_2) &= \left[-1.58 - 2.57 \frac{\sqrt{3.04}}{\sqrt{6}}, -1.58 + 2.57 \frac{\sqrt{3.04}}{\sqrt{6}} \right] \\ &= [-3.41, 0.25]. \end{aligned}$$

Resumen: Intervalos de Confianza para $\mu_1 - \mu_2$

Caso	Pivote y Distribución	Intervalo de Confianza
Muestras Independientes Varianzas Conocidas	$Z = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$ $Z \sim N(0, 1)$	$\left[(\bar{X} - \bar{Y}) \pm z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right]$
Muestras Independientes Varianzas Iguales	$T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$ $T \sim t_{n_1+n_2-2}$	$\left[(\bar{X} - \bar{Y}) \pm t_{\alpha/2, n_1+n_2-2} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right]$ $S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$
Muestras Independientes Varianzas Distintas	$T^* = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}$ $T^* \approx t_\nu$	$\left[(\bar{X} - \bar{Y}) \pm t_{\alpha/2, \nu} \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}} \right]$ $\nu = \frac{\left(\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2} \right)^2}{\frac{(S_1^2/n_1)^2}{n_1-1} + \frac{(S_2^2/n_2)^2}{n_2-1}}$

Resumen: Intervalos de Confianza para $\mu_1 - \mu_2$

Caso	Pivote y Distribución	Intervalo de Confianza
Muestras Pareadas	$T = \frac{\bar{D} - \mu_D}{S_D / \sqrt{n}}$ $T \sim t_{n-1}$ $D_i = X_i - Y_i, \bar{D} = \frac{1}{n} \sum D_i$	$\left[\bar{D} \pm t_{\alpha/2, n-1} \frac{S_D}{\sqrt{n}} \right]$

- ▶ $\bar{X}, \bar{Y}$: medias muestrales; S_1^2, S_2^2 : varianzas muestrales
- ▶ $N(0, 1)$: distribución normal estándar; t_ν : distribución t-Student con ν grados de libertad
- ▶ $z_{\alpha/2}$: valor crítico de $N(0, 1)$; $t_{\alpha/2, \nu}$: valor crítico de t_ν

Observaciones

- ▶ Para muestras grandes ($n_1, n_2 \geq 30$) con varianzas desconocidas, se puede usar $z_{\alpha/2}$ en lugar de $t_{\alpha/2, \nu}$
- ▶ En muestras apareadas, n es el número de pares de observaciones